



MUNJIZ

هذا مرجع تقني لمنصة **منجز** · **تقييم القرض العقاري الأولي**. يشرح تصميم الوكلاء متعددة النماذج، وطريقة تبادل السياق عبر A2A، ومسار الطلب من إدخال البيانات حتى التوصية النهائية، وما يلزم للأمان والامتثال والتشغيل. أُعد للمهندسين والمدققين والجهات التنظيمية.

Technical reference for Munjiz Mortgage AI: multi-model agent design, A2A communication, the mortgage application review flow, security and compliance posture, and production economics. Written for engineers, auditors, and regulators.

Version **v1.0** Status **Pilot-ready** Pages **14**

Stack Django · Channels · Celery · Redis · PostgreSQL · Docker

LLM Surface OpenRouter (Claude · GPT · Qwen · DeepSeek)

الفهرس

Executive Summary • الملخص التنفيذي 01

System Architecture • المعمارية النظامية 02

Heterogeneous Design • المعمارية متعددة النماذج 03

A2A • Agent-to-Agent Protocol بروتوكول 04

Agent Specifications • مواصفات الوكلاء 05

End-to-End Flow • تدفق التنفيذ الكامل 06

Data Model • نموذج البيانات 07

API • API Surface واجهة 08

Resilience & Fallback • الصمود والتعافي 09

Deployment Architecture • معمارية النشر 10

Security & Compliance • الأمان والامتثال 11

Economics & Scale • الاقتصاديات والقياس 12

Observability & Audit • المراقبة والتدقيق 13

Roadmap • خارطة الطريق 14



الملخص التنفيذي

منجز منصة وكلاء ذكاء اصطناعي تساعد البنوك السعودية على مراجعة طلبات القرض العقاري. يمر كل طلب على خمسة وكلاء متخصصين، ثم يخرج النظام بتوصية أولية واضحة تراعي السياق المحلي والضوابط التنظيمية.

01

منجز • تقييم القرض العقاري الأولي طبقة ذكية لمراجعة طلبات التمويل العقاري. تضم **خمس وكلاء متخصصين**، ولكل وكيل نموذج LLM يناسب مهمته: الجدارة الائتمانية، التحقق من الهوية والأهلية القانونية، قدرة العميل والدعم، تقييم العقار والضمان، ثم التوصية النهائية. يتبادل الوكلاء السياق عبر بروتوكول A2A داخلي، ويصدرون توصية أولية مرتبة (موافقة / مشروطة / مراجعة بشرية / غير موصى) خلال أقل من دقيقتين، بصياغة عربية واضحة، وحدود صلاحيات معلنة، وسجل تدقيق يمكن الرجوع إليه.

Munjiz Mortgage AI is an intelligent review layer for Saudi mortgage applications. **Five specialized agents** — Credit, Identity & Legal, Capacity & Support, Collateral, and the Orchestrator — each use an LLM suited to the task, coordinate through an internal A2A protocol, and produce a structured pre-approval recommendation in under two minutes, in clear Arabic, with explicit authority limits and a traceable audit record.

60s~

END-TO-END PRE-APPROVAL

5

HETEROGENEOUS LLMS

5

SPECIALIZED AGENTS

100%

DECISIONS AUDIT-LOGGED

4

RECOMMENDATION OUTCOMES

\$0.08~

COST PER APPLICATION

تقييم طلب التمويل العقاري يجمع بيانات من مصادر مختلفة (SIMAH، أبشر/يقيين، تحقق من جهة العمل، Sakani أو تثمين العقار)، ثم يراجع جدارة العميل وأهليته القانونية وقدرته الفعلية وضمانه. منجز يرتب هذه المراجعة المتكررة في مسار ثابت، ويترك الحالات الحدية للمراجع البشري.

A mortgage application review pulls data from multiple sources — SIMAH, Absher/Yakeen, employer verification, Sakani or independent valuation — and weighs creditworthiness, legal eligibility, real affordability, and collateral. Munjiz turns that repeatable review into a consistent, structured path, leaving edge cases to a human reviewer.



المعمارية النظامية

يمتد النظام من المتصفح إلى مزودات النماذج. كل طبقة لها مسؤولية واضحة، ويمكن اختبارها أو استبدالها دون إعادة بناء النظام كله.

02

الطبقات السبع · Seven Layers

- 01 **Browser Layer** — Vanilla JavaScript + Alpine.js + Tailwind
طبقات، ونظام ثيمات، وتجربة عربية RTL أولاً. عميل WebSocket مع dedupe بثلاث
- 02 **Edge / Reverse Proxy** — Nginx
يخدم الملفات الثابتة، ويمرر HTTP إلى Daphne ASGI server، ويدعم ترقية اتصال WebSocket.
- 03 **Application Layer** — Django 5 + Django Channels + DRF
يستقبل طلبات HTTP وإطارات WebSocket. ويدفع المهام الطويلة إلى Celery.
- 04 **Async Compute Layer** — Celery workers
Redis queue وتشغل **AgentEngine** مع سياق الطلب. (instance لكل concurrency=4) تلتقط مهام مراجعة الطلبات من
- 05 **Agent Engine** — قلب النظام. **AgentEngine.run_review_with_ai(application)** يستدعي الوكلاء الخمسة بالتسلسل، وكل وكيل يستخدم LLM مختلفاً عبر OpenRouter API ويقرأ نتائج الفحوصات المناسبة لدوره (SIMAH, Absher, Sakani...).
- 06 **Data Layer** — PostgreSQL 16
النهائية، وسجلات التدقيق. Redis يستخدم لـ message broker و channel layer. التوصية

مخطط النظام الكامل · Full System Diagram



الفكرة الأساسية: كل طبقة تعرف ما تحتاجه فقط. ال AgentEngine لا يهتم إن كان الاستدعاء قادماً من Celery أو من Django shell. وال DashboardConsumer لا يحتاج أن يعرف مزود ال LLM خلف كل وكيل؛ يستقبل رسائل موحدة فقط. هذا يجعل التبديل والاختبار والتشغيل أوضح وأسهل في الصيانة.

// HETEROGENEOUS MULTI-MODEL ARCHITECTURE



المعمارية متعددة النماذج

اختيار النماذج في منجز ليس نسخة واحدة للجميع. كل وكيل يستخدم النموذج الأقرب لطبيعة دوره، مع موازنة بين جودة التفكير والتكلفة وثبات المخرجات.

03

لماذا ليس نموذجاً واحداً؟ · Why Not a Single Model?

الاعتماد على نموذج واحد يعني التنازل في جانب ما. **Claude Opus** قوي في الموازنة بين توصيات الموافقة والشروط لكنه مكلف. **GPT-4o-mini** سريع ومنضبط مع قواعد التحقق من الهوية والأهلية القانونية، لكنه ليس الأفضل في الصياغة العربية. **Qwen3 80B** ممتاز عربياً وفي حوار قدرة العميل، لكنه ليس الخيار الأول لحسابات SIMAH و DBR. **DeepSeek V3.2** اقتصادي ومفيد في الاستدلال الرقمي على الجدارة الائتمانية، لكنه أقل مناسبة لتقييم العقار متعدد العوامل. لذلك يقوم التصميم على فكرة مباشرة: النموذج المناسب في المكان المناسب.

المعايير الثلاثة لاختيار النموذج · Three Selection Criteria

// 03

موثوقية الإخراج

الجودة وحدها لا تكفي؛ نحتاج مخرجات يمكن الاعتماد عليها في كل تشغيل. في الاختبار العملي، كان DeepSeek R1 يستهلك الميزانية في التفكير الداخلي ثم يعيد content فارغاً، لذلك استبدلناه بـ V3.2 instruct.

// 02

التكلفة لكل طلب

سعر المليون توكن وحده لا يكفي للحكم. الرقم الأهم هو تكلفة مراجعة طلب واحد بحجم المدخلات الفعلي. تشغيل كل شيء على Opus يصل إلى \$٠.٢٥ للطلب، بينما التصميم المتعدد يقارب \$٠.٠٨، أي وفر يقارب ٧٠٪.

// 01

الملاءمة المعرفية

هل يثبت النموذج قوته في هذه المهمة تحديداً؟ Claude Opus لتوصية الموافقة النهائية، Sonnet لتقييم العقار وموازنة القيمة العادلة مع السعر المُعلن، DeepSeek لحسابات الجدارة الائتمانية، Qwen للحوار العربي حول قدرة العميل، و GPT-4o-mini للتحقق المنضبط من الهوية والأهلية. الاختيار مبني على نتائج، لا على الانطباع العام.

الوكيل / Agent	النموذج / Model	درجة الحرارة	السبب / Rationale	تكلفة/قرار
سارة / Sara - Credit	DeepSeek V3.2	0.2	تحليل SIMAH + DBR التزامات بأقل تكلفة	\$0.003~
فهد / Fahad - Identity	OpenAI GPT-4o mini	0.3	تحقق من الهوية والأهلية والقيود القانونية	\$0.0008~
خالد / Khalid - Capacity	Qwen3 80B Instruct	0.7	صياغة عربية لقدرة العميل والدعم والإفصاحات	\$0.0015~
نورة / Nora - Collateral	Anthropic Claude Sonnet 4.5	0.6	تقييم العقار: قيمة عادلة، مسار Sakani، LTV	\$0.025~
المنسق / Orchestrator	Anthropic Claude Opus 4.7	0.2	توصية نهائية مرتبة + شروط + مخاطر متبقية	\$0.05~

// VENDOR INDEPENDENCE

كل `model_name` محفوظ في قاعدة البيانات داخل `Agent.model_name`، وليس مكتوباً داخل الكود. إذا ظهر نموذج أفضل لاحقاً، يكفي تحديث صف واحد في قاعدة البيانات. هذا يقلل الارتباط بمزود واحد ويجعل التطوير أسرع.

// AGENT-TO-AGENT PROTOCOL



بروتوكول A2A

يوضح الجزء التالي كيف يتبادل الوكلاء الرسائل والسياق، ولماذا يأتي كل وكيل في ترتيبه داخل سلسلة اتخاذ القرار.

04

المغلف الموحد · The Unified Envelope

كل تفاعل بين الوكلاء يمر عبر `AgentMessageEnvelope`، وهو `dataclass` موحد يجعل الرسائل مفهومة لكل أجزاء النظام، حتى لو كانت النماذج المستخدمة خلف الوكلاء مختلفة.

```
# apps/agents/a2a_protocol.py
```

```
@dataclass
```

```
class AgentMessageEnvelope:
```

```
    from_agent: str                                # 'analytics' | 'operations' | 'customer' | 'qu
    content: str                                    # الرد الكامل للوكيل بالعربية
    message_type: str = 'update'                   # analysis | update | suggestion | decision | al
    priority: str = 'medium'                        # low | medium | high | critical
    to_agent: Optional[str] = None                  # None = broadcast لكل التبويبات
    to_broadcast: bool = True
    raw_data: Optional[dict] = field(default=None) # التي بنى عليها الوكيل قراره
```

تسلسل المراجعة • The Review Sequence

الترتيب مقصود ويحاكي طريقة مدير ائتمان متمرس: نبدأ بالجدارة الائتمانية، ثم الهوية والأهلية القانونية، ثم قدرة العميل والدعم، ثم تقييم العقار/الضمان، وأخيراً التوصية النهائية.

سارة (الجدارة الائتمانية) • Sara (Credit)

01

تبدأ سارة لأن الجدارة الائتمانية هي بوابة الطلب. تقرأ بيانات SIMAH (الدرجة، التأخرات، الالتزامات المفتوحة) وتحسب DBR بعد التمويل المطلوب، ثم تقدم حكماً رقمياً مع نسبة ثقة.

فهد (الهوية والقانوني) • Fahad (Identity & Legal)

02

يتحقق فهد من الهوية عبر أبشر/يقين، ويطابق راتب العميل مع جهة العمل، ويفحص أي قيود قانونية مثل إيقاف الخدمات أو حظر السفر. يضيف حالة الهوية، وتطابق صاحب العمل، وقائمة الحواجز إن وجدت.

خالد (قدرة العميل والدعم) • Khalid (Capacity & Support)

03

يفحص خالد القدرة الفعلية للعميل والإفصاحات الطوعية: اللغة، احتياجات الوصول، وليّ الشؤون القانوني، والحاجة إلى استشارة مستقلة. يضيف علامات الدعم اللازمة ويحدد الحاجة إلى ممثل قانوني.

نورة (تقييم العقار) • Nora (Collateral)

04

تقيم نورة العقار والضمان. تختار مسار Sakani أو التثمين المستقل، وتقارن السعر المُعلن بالقيمة العادلة، وتحسب LTV، وتضع إشارة عند وجود فجوة كبيرة.

آلية تمرير السياق · Context Passing Mechanism

Mandated Output Structure · صيغة الإخراج

البروتوكول الحالي بسيط عمداً. إذا احتجنا لاحقاً إلى workflows غير متزامنة، أو تنسيق بين فروع متعددة، أو agent discovery، يمكن توسيعه باتجاه معيار Google A2A الكامل دون تغيير كبير في شكل الرسالة الحالي.



مواصفات الوكلاء التفصيلية

لكل وكيل دور واضح، نموذج مناسب، مدخلات ومخرجات معروفة، وحدود صلاحية لا يتجاوزها.

05

سارة · Sara — الجدارة الائتمانية

01

MODEL: deepseek/deepseek-v3.2 · TEMP: 0.2 · COLOR: #FF1744 · TYPE: analytics

المسؤولية: تقرأ بيانات SIMAH وتاريخ الالتزامات، وتحسب DBR بعد التمويل المطلوب، ثم تصدر حكماً رقمياً (آمن / تحذير / خطر) مع نسبة ثقة. كل حكم تقدمه يكون مستنداً إلى رقم واضح.

المدخلات: applicant (راتب، التزامات شهرية، عمر)، application (مبلغ التمويل، المدة)، SIMAH من compliance snapshot.

المخرجات (structured JSON): `simah_score_demo` , `dbr_after_loan_percent` , `verdict` , `late_payments` , `open_obligations`.

عيّنة برومبت نظامي:

- لا تخرجي بحكم لا يدعمه رقم
- مركيزتين SIMAH score + DBR استخدمي
- آمن · 600-749 تحذير · 600 > خطر SIMAH ≥ 750 bands:
- آمن · 46-55% تحذير · 55% < خطر DBR ≤ 45% bands:
- [مبّرر مختصر] + [الحكم] + [التفسير] + [DBR + الدرجة] [🇸🇦]: صياغة ردك

MODEL: openai/gpt-4o-mini · TEMP: 0.3 · COLOR: #FF6D00 · TYPE: operations

المسؤولية: يتحقق من الهوية عبر أبشر/يقين، ويطابق راتب العميل مع جهة العمل المُعلَّنة، ويفحص أي قيود قانونية. يعطي نتيجة واضحة، ويحوّل أي شك إلى المنسق.

المخرجات (structured JSON): `identity_check_demo` (passed / flagged / failed), `employer_verification_demo`, `salary_match`, `legal_blockers_demo`.(list)

قواعد الصلاحيات:

- ▶ الهوية مطابقة + جهة العمل مؤكدة + لا قيود ← يدفع للمراجعة العادية
- ▶ أي علامة *flagged* أو حاجز قانوني ← يصعد إلى المنسق مباشرة
- ▶ فشل التحقق التام ← يوصي بـ `not_recommended` قبل وصول باقي الوكلاء

MODEL: qwen/qwen3-next-80b-a3b-instruct · TEMP: 0.7 · COLOR: #2979FF · TYPE: customer

المسؤولية: يفحص القدرة الفعلية للعميل والإفصاحات الطوعية المُدخلة في مرحلة الفحص (وليّ شؤون، حاجة وصول، حاجة ترجمة، استشارة مستقلة)، ويحوّلها إلى علامات واضحة للمنسق.

المخرجات (structured JSON): `support_needs_flagged` (list), `needs_legal_representative`, `ethical_ok`.

درجة الحرارة 0.7 — أعلى من غيره لأن صياغة الإفصاحات تحتاج لغة طبيعية ومحترمة، لا قائمة جامدة.

لغة: صياغة عربية واضحة ومهذبة، وليست ترجمة حرفية من الإنجليزية.

MODEL: anthropic/claude-sonnet-4.5 · TEMP: 0.6 · COLOR: #AA00FF · TYPE: queue

المسؤولية: تقيّم العقار والضمان: تختار مسار Sakani عند الإمكان أو التثمين المستقل، وتستخرج القيمة العادلة، وتقارنها بالسعر المُعلن، وتحسب LTV (نسبة التمويل إلى قيمة العقار).

المخرجات (structured JSON): `valuation_path` (sakani / independent), `verified_value_sar`, `declared_price_sar`, `discrepancy_flag`, `ltv_percent`

bands: LTV ≤ 80% آمن · 81-90% تحذير · > 90% خطر. انحراف < 10% بين القيمة المُعلّنة والقيمة العادلة → إشارة انحراف تدفع التوصية إلى مسار الشروط.

المنسق · The Orchestrator

05

MODEL: anthropic/claude-opus-4.7 · TEMP: 0.2 · COLOR: #00C853 · TYPE: orchestrator

المسؤولية: يجمع مخرجات الوكلاء الأربعة ويصدر **توصية مرتبة** من أربعة احتمالات حصرية:

`recommend_initial_approval` · `recommend_approval_with_conditions` · `needs_human_review` · `not_recommended`

المخرجات (structured JSON): `recommendation`, `summary_per_agent` (dict), `conditions_if_any` (list), `residual_risks_for_human_review` (list), `binding=False` (التوصية مساعدة قرار وليست قراراً ملزماً).

قواعد التصعيد: أي حاجز قانوني من فهد، أو الحاجة لوليّ شؤون من خالد، أو علم انحراف عقار من نورة، أو SIMAH تحت ٦٠٠ من سارة → التوصية لا تكون `initial_approval` دون مرور بمراجع بشري. **درجة الحرارة 0.2** — منخفضة لأن التوصية يجب أن تكون ثابتة وقابلة للتدقيق.



تدفق التنفيذ الكامل

من إدخال الطلب ورفع المستندات إلى ظهور التوصية النهائية على الشاشة، هذا هو مسار مراجعة الطلب داخل النظام.

06

المراحل الثمانية • The Eight Stages

01 الواجهة تُنشئ الطلب وترفع المستندات

01

يدخل موظف القروض بيانات المتقدم والعقار في Stage 01، ويرفع المستندات (هوية، تعريف بالراتب، خطاب بنكي، بيان Sakani أو صك). بعدها تستدعي الواجهة:

```
Applications/ # حالة MortgageApplication يُنشئ
Applications/<id>/documents/ # لكل مستند مرفوع
Applications/<id>/compliance-preview/ # preview الفحوصات قبل التشغيل
```

02 المستخدم يضغط "بدء المراجعة" → POST /trigger

02

ترسل الواجهة View . POST /api/applications/<id>/trigger/ Django الـ يحدّث application.status = 'under_review' ثم يرسل المهمة إلى Celery عبر run_review_task.delay(application_id) ، ويعيد ack مباشرة بزمان استجابة أقل من 50ms.

03 Celery worker يلتقط مهمة المراجعة من Redis queue

03

تبني الـ task السياق من قاعدة البيانات عبر applicant, application.to_context() : application, property, screening_answers, documents. ثم تمرر السياق إلى AgentEngine.run_review_with_ai(application) ، حيث يعمل الوكلاء الخمسة بالتسلسل عبر OpenRouter.

04 review_started broadcast

04

قبل تشغيل أي وكيل، يرسل الـ engine حدث lifecycle باسم review_started إلى group <application:<id> في Redis pub/sub. كل تبويب مفتوح للطلب يستقبل الحدث ويمسح أي مراجعة قديمة، حتى لا تختلط الرسائل بين الطلبات.

لكل وكيل بالتسلسل (Sara → Fahad → Khalid → Nora → Orchestrator):

أ. تحديث `agent.status = 'thinking'` ، ثم broadcast للواجهة حتى يظهر مؤشر التفكير.

ب. بناء `user_message` : سياق الطلب + مراجعات الوكلاء السابقين.

ج. استدعاء

`OpenAI(base_url=openrouter).chat.completions.create(...)` ←
POST openrouter.ai

د. فحص `response.choices[0].message.content` — إذا فارغ → `raise`
`.LLMUnavailable`

هـ. حفظ `AgentReview(content, structured, compliance_snapshot)` في
PostgreSQL

و. بث الرسالة + الـ JSON `structured` إلى الواجهة.

ز. تحديث broadcast ، `agent.status = 'done'` .

FinalRecommendation persistence + review_ended

06

بعد انتهاء المنسق، يستخرج الـ engine الـ `structured` من مراجعته ويحفظ صفراً واحداً في

`FinalRecommendation (recommendation + conditions_if_any +`
`residual_risks_for_human_review)`. بعدها تتغير حالة الطلب إلى `review_complete`
ويُثبت `review_ended` .

المتصفح يستقبل ١٠-١٥ event عبر WebSocket

07

يمر كل event عبر `MunjizBus` ، وهو EventTarget داخلي، بعد ثلاث طبقات dedupe: IIFE
init guard، و `seenMessageIds` على مستوى الـ bus، وفحص `data-msg-id` على مستوى
DOM. كل event يحمل `agent_type` و JSON `structured` يغذي حقول liveNumbers في
الواجهة (...sara.simah, fahad.id_status).

الانتقال إلى Stage 03 — تقرير التوصية

08

عند استلام `review_ended` تنتقل الواجهة إلى Stage 03 وتنادي GET

`//api/applications/<id>/report` لاسترجاع التقرير الكامل (FinalRecommendation
+ AgentReview list). بعدها يظهر الـ recommendation pill (موافقة أولية / مشروطة / مراجعة
بشرية / غير موصى) مع قوائم الشروط والمخاطر المتبقية.

المرحلة	الكمون النموذجي	الملاحظات
POST /trigger → Celery	ms 50 >	local Redis
Sara – Credit (DeepSeek V3.2)	s 8~5~	سريع نسبياً
Fahad – Identity (GPT-4o mini)	s 5~3~	الأسرع
Khalid – Capacity (Qwen3 80B)	s 12~8~	عربي طويل
Nora – Collateral (Claude Sonnet 4.5)	s 18~12~	تقييم متعدد العوامل
Orchestrator (Claude Opus 4.7)	s 35~25~	الأطول لأنه يوازن كل المدخلات
Total wall-clock	s 90~60~	المجموع يتأثر بأبطأ خطوة في السلسلة

نموذج البيانات

يعتمد النظام على خمسة جداول رئيسية في تطبيق **mortgage**، تغطي ملف المتقدم، والطلب، والمستندات، ومراجعات الوكلاء، والتوصية النهائية. صُممت هذه الجداول كسجل تدقيق append-only.

07

الجدول الخمسة · Five Tables

الغرض	الحقول الرئيسية	Model
ملف المتقدم (مرتبط بـ ID مرجعي للأنظمة الأم)	applicant_id · name_ar · national_id · nationality · age · monthly_salary_sar · existing_monthly_obligations_sar · employer_name · employer_sector · employment_duration_months	Applicant
الطلب الفعلي + خيارات الفحص الأخلاقي الطوعي	application_id · applicant FK · requested_loan_sar · requested_term_years · property_source · property_id · property_declared_price_sar · screening_answers (7 boolean) · status	MortgageApplication
المستندات المرفوعة لكل طلب	application FK · kind (national_id / salary_slip / employment_letter / bank_statement / property_deed / property_listing) · file · file_size_bytes · uploaded_at	Document
مراجعة الوكيل + JSON منظم + لقطة الفحوصات	application FK · agent_type · order · content · structured (JSON) · compliance_snapshot (JSON) · is_demo · created_at	AgentReview
التوصية النهائية المنظمة (denormalised) لسرعة الاستعلام	application 1:1 · recommendation · summary_per_agent · conditions_if_any · residual_risks_for_human_review · binding · demo_mode	FinalRecommendation


```
class AgentReview(models.Model):
    id = UUIDField(primary_key=True, default=uuid.uuid4)
    application = ForeignKey(MortgageApplication, related_name='reviews')
    agent_type = CharField(choices=AGENT_TYPES) # analytics / operations / .
    order = IntegerField(default=0) # الترتيب في السلسلة

    content = TextField() # السرد العربي الكامل
    structured = JSONField(default=dict) # JSON parsed من المخرج
    compliance_snapshot = JSONField(default=dict) # المراجعة SIMAH/Absher نقطة

    is_demo = BooleanField(default=True)
    created_at = DateTimeField(auto_now_add=True)
```

FinalRecommendation – الإخراج المنظم

```
class FinalRecommendation(models.Model):
    RECOMMENDATIONS = [
        ('recommend_initial_approval', 'توصية بالموافقة الأولية'),
        ('recommend_approval_with_conditions', 'توصية بموافقة مشروطة'),
        ('needs_human_review', 'يحتاج مراجعة بشرية'),
        ('not_recommended', 'غير موصى بها'),
    ]

    application = OneToOneField(MortgageApplication)
    recommendation = CharField(choices=RECOMMENDATIONS)
    summary_per_agent = JSONField(default=dict)
    conditions_if_any = JSONField(default=list)
    residual_risks_for_human_review = JSONField(default=list)
    binding = BooleanField(default=False) # pre-approval فقط
    demo_mode = BooleanField(default=True)
```

// AUDIT TRAIL DESIGN

يحفظ `compliance_snapshot` نسخة من فحوصات SIMAH وأبشر/يقين و Sakani التي اعتمد عليها الوكيل. إذا احتاج المدقق بعد سنة إلى فهم توصية معينة، يمكن إعادة بناء السياق الكامل الذي كان أمام الوكيل في تلك اللحظة: المتقدم، الطلب، العقار، الفحوصات، ومراجعات الزملاء. بهذا لا يبقى التدقيق معتمداً على النتيجة النهائية وحدها.

هذا ال schema خاص بالمرحلة التجريبية. عند الإنتاج، تُستبدل ال Applicant و MortgageApplication بجدول ال LOS الرسمي للبنك (Loan Origination System)، ويبقى Munjiz مسؤولاً عن AgentReview + FinalRecommendation فقط، مع foreign key إلى application_id الخارجي. بهذه الطريقة يبقى التدقيق محفوظاً دون تكرار بيانات العميل.



واجهة API

تجمع الواجهة بين REST endpoints و WebSocket: endpoints للقراءة والتشغيل، وقناة واحدة للتحديثات الحية.

08

REST Endpoints

Purpose	Path	Method
قائمة المتقدمين التجريبيين (لتعبئة سريعة في الواجهة)	/api/applicants/	GET
إنشاء طلب جديد MortgageApplication بحالة draft	/api/applications/	POST
رفع مستند (multipart/form-data) لطلب موجود	/api/applications/<id>/documents/	POST
preview للفحوصات (SIMAH, Absher, Sakani) قبل التشغيل	api/applications/<id>/compliance-/ /preview	GET
تشغيل مراجعة الوكلاء الخمسة → Celery.delay()	/api/applications/<id>/trigger/	POST
التقرير النهائي = FinalRecommendation + AgentReview list	/api/applications/<id>/report/	GET
ال WebSocket الحي لمتابعة المراجعة لحظياً	/<ws>/applications/<id>/	WS

```
{ "action": "subscribe", "application_id": "DEMO-APP-001" }  
{ "action": "ping" }
```

:Server → Client (broadcasted on group `application:<id>`)

```
{ "type": "hello" } // connection ack  
{ "type": "status_update", "agent_type": "analytics", "status": "thinking" }  
{ "type": "review_started", "application_id": "DEMO-APP-001", "mode": "ai" }  
{ "id": "uuid", "from_agent": "analytics",  
  "content": "🇮🇹 SIMAH 752 • DBR 41%. ",  
  "structured": { "simah_score_demo": 752, "dbr_after_loan_percent": 41, "verdict": "s  
  "is_ai_generated": true } // agent review even  
{ "type": "review_ended", "application_id": "DEMO-APP-001",  
  "recommendation": "recommend_approval_with_conditions" }
```

// RESILIENCE & MULTI-PROVIDER FAILOVER



الصمود والتعافي

يتعامل النظام مع الفشل كاحتمال وارد: يعيد المحاولة، ويتحقق من المخرجات، ويمكنه التحول بين مزودين عند الحاجة.

09

// LAYER 03

Validated Output

كل رد يُفحص قبل قبوله: `if not result.strip(): raise LLMUnavailable(...)`. أي محتوى فارغ أو غير صالح يفعل retry policy تلقائياً.

// LAYER 02

Multi-Provider Failover

نفس الواجهة المتوافقة مع OpenAI متاحة عبر OpenRouter, Anthropic Direct, Groq, Azure OpenAI, Ollama-local. إذا فشل المزود الأساسي، ينتقل الطلب إلى المزود التالي حسب priority list.

// LAYER 01

SDK Auto-retry

OpenAI SDK يعيد المحاولة تلقائياً عند 2 rate limits (default: exponential backoff مع retries). هذا يعالج أغلب الفشل العابر دون تدخل من المستخدم.

01 **OpenRouter slug evolution**: النموذج الأول (`qwen-2.5-72b-instruct:free`) ألغى من OpenRouter. ظهر الخطأ في celery logs، فتم الانتقال إلى `qwen3-next-80b-a3b-instruct` المدفوع. لأن اسم النموذج محفوظ في DB، بقي التغيير محصوراً في صف واحد ودون downtime.

02 **Sara model selection**: اختبرنا DeepSeek R1، وظهر أنه يستهلك max_tokens في "thinking chain" داخلي ثم يعيد محتوى فارغاً. لذلك انتقلنا إلى DeepSeek V3.2 instruct، وهو أكثر ثباتاً لهذا الدور.

03 **Cross-tab synchronization**: تشغيل مراجعة طلب من تبويب واحد يثبت الرسائل لكل التبويبات المشتركة في `<group application:<id review_started` قبل بدء الرسائل.

04 **Alpine x-init guard**: كان Alpine 3 يستدعي init () تلقائياً، ومع `"()x-init="init` كان التسجيل يحدث مرتين. حذفنا `x-init` وأضفنا `initDone` idempotency guard_ لمنع تكرار الرسائل.

// FAILOVER PRIORITY

ترتيب الإنتاج المقترح هو: `OpenRouter → Anthropic Direct → Groq → Ollama-local`. بما أن ال engine يعتمد على `base_url` قابل للتغيير، يتم التحويل بين المزودين عبر env var، لا عبر تعديل الكود.

// DEPLOYMENT ARCHITECTURE



معمارية النشر

يبدأ النشر بـ Docker Compose لـ pilot، ثم ينتقل إلى Kubernetes عند التوسع. يمكن تشغيله سحابياً، أو هجيناً، أو داخل بيئة البنك بالكامل.

10

Docker Compose Stack (Pilot)

في نسخة ال pilot، يعمل النظام عبر ٦ خدمات داخل compose واحد:

Purpose	Image	Service
HTTP + WebSocket via ASGI	Custom (Python 3.12 + Daphne)	web
تشغيل المهام الطويلة (concurrency=4)	Same as web	celery_worker
المهام الدورية (تنظيف الطلبات المنتهية، تجميع التكاليف اليومية)	Same as web	celery_beat
البيانات الدائمة	postgres:16-alpine	db
channel layer + celery broker + cache	redis:7-alpine	redis
reverse proxy + static files	nginx:alpine	nginx

خيارات النشر للبنوك · Bank Deployment Options

// C · ON-PREM

تشغيل محلي بالكامل

كل المكونات تعمل داخل datacenter البنك، مع LLM محلي على NVIDIA H100/H200، واتصال داخلي مباشر بأنظمة LOS و SIMAH gateway. هذا المسار مناسب للبنوك الحكومية أو الجهات ذات متطلبات سيادية عالية.

SECURITY LEVEL: **MAXIMUM**

// B · HYBRID

هجين

تعمل منصة منجز في السحابة، بينما تعمل LLMs محلياً عبر Ollama على GPU داخل datacenter البنك. بهذا لا تُرسل بيانات SIMAH أو Absher أو وثائق المتقدم إلى مزود LLM خارجي.

SECURITY LEVEL: **HIGH**

// A · CLOUD

السحابة الإقليمية

AWS Riyadh / Azure Riyadh / STC Cloud، مع تمرير LLM calls عبر OpenRouter داخل المنطقة، وفصل واضح بين منجز و الـ LOS الرسمي للبنك (يتصلان بـ + webhook signed REST). هذا مناسب لمعظم البنوك التجارية في بداية التشغيل.

DATA RESIDENCY: **KSA**

يراعي التصميم متطلبات الأمن السيبراني البنكي، ونظام حماية البيانات الشخصية، وحساسية بقاء البيانات داخل المملكة.

طبقات الأمان السبع · Seven Security Layers

- 01 **Encryption in Transit: TLS 1.3** لكل HTTP و WebSocket. الشهادات من Let's Encrypt أو من CA محلي معتمد.
- 02 **Encryption at Rest**: تشفير PostgreSQL عبر AWS KMS أو Azure Key Vault، مع إدارة المفاتيح من خلال .HSM
- 03 **Authentication & RBAC**: Keycloak أو Azure AD مع MFA إلزامي للواجهة. الأدوار الأساسية: Loan Officer, Credit Reviewer, Compliance Auditor, Admin
- 04 **Network Segmentation**: ال stack داخل VPC مخصص. قاعدة البيانات بلا اتصال مباشر بالإنترنت، و LLM calls تمر عبر egress proxy مراقب، واتصالات SIMAH / Absher / Sakani عبر private link / VPN معتمد.
- 05 **Audit Logging**: كل قرار AI، وكل تغيير في DB، وكل authentication event يكتب في log append-only داخل S3 Object Lock مع retention لمدة ٧ سنوات.
- 06 **Secrets Management**: HashiCorp Vault أو AWS Secrets Manager. لا secrets داخل environment variables، ولا داخل الكود، ولا داخل DB.
- 07 **Incident Response**: تنبيهات PagerDuty عند LLMUnavailable burst < ٥/دقيقة، أو authentication failure < ١٠/دقيقة، أو cost spike < ٢٠٠٪ من baseline.

PDPL — حماية بيانات العملاء

السؤال الحساس هنا واضح: ما الذي يصل فعلاً إلى النماذج الخارجية؟ التصميم يخفف المخاطر عبر ثلاث طبقات:

// 03

On-Prem Option

للبنوك الأكثر تحفظاً، يمكن تشغيل Ollama + Qwen3 على GPU محلي، بحيث لا تغادر بيانات SIMAH ولا وثائق العميل بيئة البنك. القرار النهائي يعتمد على مستوى المخاطر المقبول.

// 02

Pseudonymization

يُستبدل اسم المتقدم باسم مستعار مثل "أبو محمد" قبل بناء البرومبت. الاسم الحقيقي ورقم الهوية يبقيان داخل DB البنك / LOS، ويرتبطان بالطلب عبر `application_id` فقط.

// 01

Data Minimization

لا يُمرر رقم الهوية الكامل أو رقم الجوال أو IBAN إلى النموذج. ما يمرر فقط هو القيم المُصنّفة المطلوبة للقرار: SIMAH score (رقم)، DBR (نسبة)، نتيجة Absher (passed/flagged)، مسار التقييم LTV، (sakani/independent) (نسبة).

// CURRENT STATUS

المرحلة الحالية هي pilot وليست نسخة إنتاج مرخصة من ساما، والتوصية النهائية `binding=False` أي أنها مساعدة قرار وليست قراراً ملزماً. طبقات الأمان أعلاه تمثل هدف النسخة الإنتاجية. أما ال MVP الحالي داخل docker-compose فلا يتضمن بعد MFA أو audit immutability أو secrets vault أو ربط حقيقي بـ SIMAH/Absher (يستخدم mock compliance snapshot)، وهذه الفجوات موثقة ومجدولة في خارطة الطريق.

الاقتصاديات والقياس

هنا نقدّر تكلفة مراجعة الطلب الواحد، وتكلفة التشغيل الشهري بحسب حجم الطلبات، والعائد المتوقع من تسريع وتوحيد التقييم الأولي.

12

التكلفة لكل طلب · Per-Application Cost

البند	USD لكل طلب	SAR (تقريباً)	الملاحظات
LLM API (الوكلاء الخمسة)	\$0.08	0.30~	OpenRouter heterogeneous routing
SIMAH / Absher / Yakeen / Sakani calls	-\$0.10 0.30	-0.40~ 1.10	تعتمد على عقد البنك مع كل مزود
تخزين + audit log	\$0.01	0.04~	Postgres + S3 Object Lock
الإجمالي / طلب	-\$0.20 0.40	-0.75~ 1.50	منخفض مقارنة بكلفة المراجع البشري

التكلفة الشهرية على حجم الطلبات · Monthly Cost at Volume

الحجم الشهري	تكلفة المراجعات (SAR)	البنية التحتية (SAR)	الإجمالي الشهري (SAR)
1,000 طلب/شهر	1,500~	3,000~	4,500~
10,000 طلب/شهر	15,000~	6,000~	21,000~
50,000 طلب/شهر	75,000~	15,000~	90,000~

الملاحظات	القيمة	المصدر
أكثر من ٩٠٪ من الطلبات تنتهي بـ initial_approval أو not_recommended دون تدخل بشري	30~ دقيقة → دقيقتين / طلب	اختصار وقت المراجع البشري
القرارات تتبع نفس الحدود (SIMAH bands · DBR bands · LTV bands) لكل طلب	تشئت قرارى > ٥٪	توحيد القرار
أثر تجاري مباشر على معدل التحويل في طلبات Sakani	من ساعات إلى ~دقيقة	تسريع زمن الاستجابة للعميل
كل توصية لها AgentReview + compliance_snapshot قابلة للاسترجاع	100٪ من القرارات	سجل تدقيق كامل

+90%

APPLICATIONS RESOLVED
WITHOUT HUMAN

60s~

AVG PRE-APPROVAL
LATENCY

\$0.30~

AVG COST / APPLICATION

100%

DECISIONS AUDIT-TRAILED

القياس الأفقي · Horizontal Scale Plan

01 **Celery Workers**: التوسع من ٤ إلى ١٦ workers لمعالجة ما يقارب ٨٠٠ طلب/ساعة/cluster.

02 **PostgreSQL**: read replicas + PgBouncer connection pooling لأن الـ AgentReview write-heavy.

03 **Redis**: cluster mode للـ pub/sub broadcast على آلاف ApplicationConsumer متزامنة.

04 **LLM API**: نقطة الضغط الأهم، لكن تعدد المزودين عبر OpenRouter يقلل خطر التوقف عند مزود واحد.

05 **Kubernetes orchestration**: EKS Riyadh / AKS Riyadh مع HPA على CPU + queue depth.

المراقبة والتدقيق

تخدم بيانات المراقبة ثلاث جهات: المهندسين، والمدققين، وموظفي القروض. كل جهة ترى ما تحتاجه من نفس السجل التشغيلي.

13

الإصدار الحالي (Pilot)

- 01 **Application Logs:** Django logging إلى Docker stdout، مع سجلات مستقلة ل Celery workers، وتسجيل حالة كل LLM call ولكل Compliance API call (mock).
- 02 **Database:** كل **AgentReview** مؤرخ ويحمل **compliance_snapshot** + **structured**. يمكن فحص التوصيات من Django admin.
- 03 **Diagnostic Console:** الواجهة تطبع **...msg received [Munjiz]** في DevTools console، وهذا مفيد أثناء التشخيص الحي.

إصدار الإنتاج (Production)

- 01 **Metrics:** Prometheus + Grafana لقياس agent latency p50/p95/p99، ونسبة نجاح LLM calls، وتكلفة المراجعة لكل طلب، وتوزيع التوصيات (initial / conditional / human / not_recommended).
- 02 **Logs:** Loki للسجلات المنظمة والقابلة للبحث عبر LogQL. Retention لمدة ٣٠ يوماً hot و٧ سنوات cold للتدقيق.
- 03 **Traces:** OpenTelemetry يتتبع كل طلب من POST /trigger إلى Celery ثم Engine ثم LLM ثم DB، لتشخيص المشاكل العميقة على مستوى application_id.
- 04 **Audit Trail:** كل توصية AI وكل تغيير DB يدخل Kafka stream ثم S3 Object Lock مع 7-year retention وسجل immutable.
- 05 **Cost Monitoring:** تجميع يومي لكل tenant من **response.usage**، مع تنبيه عند تجاوز الميزانية لكل ١,٠٠٠ طلب.
- 06 **Compliance Dashboard:** لوحة للمدققين تعرض عدد التوصيات حسب النوع، نسب الحالات المصعدة للمراجع البشري، حالات override اليدوي، وتوزيع SIMAH/DBR/LTV bands.

من منظور الحوكمة، يستطيع المدقق فتح "Decision Explainer" لأي قرار AI ورؤية: (١) السياق الكامل الذي رآه الوكيل، (٢) البرومبت النظامي وقتها، (٣) raw API response من LLM، (٤) ردود الوكلاء الآخرين التي بُني عليها القرار، (٥) النموذج المستخدم وإصداره. بهذا يصبح القرار قابلاً للفهم والمراجعة، لا مجرد نتيجة نهائية.



خارطة الطريق

تبدأ خارطة الطريق بإثبات القيمة على بنك واحد، ثم التوسع إلى عدة بنوك، وبعدها إلى منصة إقليمية متعددة المنتجات (تمويل عقاري، تمويل شخصي، SME).

14

السنة الأولى — Pilot & Proof

Y1

- ▶ Shadow Mode على ١,٠٠٠ طلب لمدة شهرين: الوكلاء يراجعون ويصدرون توصيات، لكن قرار البنك يبقى يدوياً، ويُقاس مدى تطابق التوصية مع القرار البشري.
- ▶ Limited Authority: تطبيق التوصية تلقائياً للحالات الواضحة (/ initial_approval not_recommended) ودفع الباقي للمراجع البشري.
- ▶ إثبات ROI بأرقام فعلية على بنك واحد، ثم توقيع عقد إنتاج.
- ▶ تجهيز ملف SAMA dossier وتقديمه (التوصية ليست قراراً ملزماً).

السنة الثانية — Multi-Tenant Rollout

Y2

- ▶ ربط حقيقي بـ SIMAH gateway و Absher/Yakeen و Sakani.
- ▶ Multi-tenancy لاستقبال البنك الثاني والثالث على نفس الـ stack.
- ▶ قنوات جديدة: تطبيق الموبايل، الإنترنت البنكي، broker portals.
- ▶ إضافة وكلاء جدد: Compliance Agent و Restructuring Agent و auto-AML check لإعادة هيكلة التمويل القائم.

- ▶ منصّة SaaS متعدّدة البنوك في المملكة لمنتجات الإقراض المختلفة.
- ▶ توسعة إقليمية إلى الإمارات ومصر والكويت، مع تكييف الفحوصات (Etihad Credit Bureau, I-Score...) ونبرة مناسبة لكل سوق.
- ▶ توسعة المنتج: تمويل شخصي، تمويل MSME، تمويل سيارات.
- ▶ Marketplace للوكلاء، بحيث تستطيع البنوك تركيب وكلاء طرف ثالث مثل anti-fraud أو climate-risk advisor.
- ▶ API عام للenterprise customers.